

Статистика и вычисления
<https://doi.org/10.1007/s11222-018-9818-2>



Об оценке параметров дисперсии нестандартных обобщенных линейных смешанных модели: применение к штрафному сглаживанию

Мария Хосе Родригес-Альварес^{1,2} · Мария Дурбан³ · Дэ-Джин Ли¹ · Пол ХК Эйлерс⁴

Получено: 16 марта 2018 г. / Принято: 5 июня 2018 г.
 © Springer Science + Business Media, LLC, часть Springer Nature 2018

Абстрактный

Мы представляем новый метод оценки параметров дисперсии в обобщенных линейных смешанных моделях. Метод имеет корни в Харвилле (J Am Stat Assoc 72 (358): 320–338, 1977), но он может работать с моделями, имеющими точность матрица для вектора случайного эффекта, линейная по отношению к параметрам дисперсии (т. е. параметрам точности). Мы называем метод SOP (разделение перекрывающихся матриц точности). СОП основана на применении метода последовательных приближения к легко вычисляемым обновлениям оценок параметров дисперсии. Эти обновления оценок имеют привлекательный форма: они представляют собой отношение (взвешенной) суммы квадратов к количеству, относящемуся к эффективным степеням свободы. Мы предоставляем достаточные и необходимые условия строго положительности этих оценок. Нарушается важная область применения СОП оценка регрессии моделей, в которых несколько квадратичных штрафов действуют на одни и те же коэффициенты регрессии. Мы обсуждаем в подробно описывают две из этих моделей: сплайны со штрафом для локально адаптивной гладкости и для данных иерархической кривой. Несколько данных представлены примеры в этих настройках.

Ключевые слова Обобщенные линейные смешанные модели · Обобщенные аддитивные модели · Параметры дисперсии · Параметры сглаживания · REML · Эффективные степени свободы

1. Введение

Оценка параметров дисперсии является статистической проблемой. Тем, которому уделялось пристальное внимание более 50 годы. Он возник на основе предложенной методологии ANOVA. Фишером в 1920-х гг., где были получены оценки приравнивание среднеквадратичной ошибки к ее ожидаемому значению. Однако результаты, полученные этим методом, не были оптимальными. в некоторых ситуациях, например, при несбалансированном данные. Позже Крамп (1951) применено максимальное правдоподобие (ML) в предположении нормально распределенных ошибок и случайные эффекты. Но только в 1970-х годах, когда

оценка параметров дисперсии на основе метода ML ods вызвали интерес. Метод *ограниченного максимума Вероятность* (REML) (Паттерсон и Томпсон 1971) дал решение проблемы смещенных оценок переменной параметры. Однако одно из главных препятствий на пути использование этой техники в то время заключалось в том, что расчет оценок ML / REML требует численного решение нелинейной задачи. Паттерсон и Томпсон (1971) предложил итеративное решение с использованием оценки Фишера. алгоритм, но это был Харвилл (1977), предложивший первый численный алгоритм вычисления REML-оценок переменной параметры. Его предложение является источником вдохновения для нашей работы.

За прошедшие годы несколько вычислительных подходов появился с целью улучшения вычислительной бремя решения балльных уравнений для параметра дисперсии Этерс: Смит (1990) предложили использовать алгоритм ЕМ, Graser et al. (1987) предложили использовать симплексный алгоритм. рифм для получения оценок непосредственно из правдоподобия, и Гилмор и др. (1995 г.) разработан метод, основанный на использовании средней информационной матрицы.

В контексте обобщенных линейных смешанных моделей (GLMM), оценка на основе итеративного повторного взвешивания REML был предложен независимо рядом авторов

В Мария Хосе Родригес-Альварес
 mxrodriguez@bcmath.org

¹ ВСАМ - Баскский центр прикладной математики, Аламеда de Mazatredo, 14, 48009 Бильбао, Страна Басков, Испания

² ИКЕРБАСК, Баскский фонд науки, Бильбао, Испания

³ Департамент статистики и эконометрики, Universidad Карлос III де Мадрид, Леганес, Испания

⁴ Медицинский центр Университета Эразма, Роттердам, Нидерланды

(например, Schall [1991 г.](#); Энгель и Кин [1994](#)), как продолжение итеративный алгоритм наименьших квадратов с повторным взвешиванием (допускает параметру сглаживания). Однако в некоторых случаях уточненные линейные модели (GLM, McCullagh и Nelder [1989 г.](#)).

Бреслоу и Клейтон ([1993 г.](#)) предложил общий метод на основе штрафной квази-правдоподобия (PQL) для оценки фиксированных и случайных эффектов, а также псевдовероятность параметры дисперсии. Как отмечают Энгель и Буист ([1996](#)), процедуры оценки, обсуждаемые во всех этих статьях, эквивалентны хороший, хотя и мотивированный с совершенно разных отправных точек.

Большинство упомянутых выше методов требуют сильное ограничение на вектор случайных эффектов: его Матрица дисперсии-ковариации должна быть линейной по дисперсии параметры. Результаты, представленные в этой статье, ослабляют то, что допущение к случаю, когда линейность по параметрам необходимо на матрице точности, а не на дисперсии - ковариационная матрица. Наш вклад мотивирован необходимостью для оценки параметров сглаживания в разрезе штрафных регрессионные модели с нестандартными квадратичными штрафами.

Штрафная сплайн-регрессия (Р-сплайны, Эйлера и Маркса [1996](#)) стал популярным методом оценки мод. els, в котором средний ответ (или линейный предиктор в негауссовский случай) является гладкой неизвестной функцией одного или несколько ковариат. Метод основан на представлении ция гладкой компоненты в терминах базисных функций и оценка параметров путем изменения правдоподобия капюшон с квадратичным штрафом на коэффициенты. Размер штраф контролируется так называемым *параметром сглаживания*. *тер*. Связь между штрафным сглаживанием и линейным смешанные модели впервые были созданы очень давно (зеленый [1987](#)), и он стал широко использоваться в последние 15 лет. (Карри и Дурбан [2002 г.](#); Currie et al. [2006](#); Ли [2010 г.](#); Палочка [2003 г.](#)). Ключевым моментом эквивалентности является то, что сглаживание становится соотношением двух параметров дисперсии.

терр. Следовательно, упомянутые выше методы могут быть использованы для непосредственной оценки количества сглаживания, необходимого в модели вместо использования методов, основанных на минимизации некоторые ошибки предсказания, такие как информация Акаике критерий (AIC), обобщенная перекрестная проверка (GCV) или Mallows' C_p (см., например, Эйлерс и Маркс [1996](#); Дресина [2008 г.](#)). В Кривококова ([2009](#)), асимптотические свойства REML и Рассмотрены оценки параметров сглаживания C_p Маллоуза. эред. В статье показано, что в рамках частотного подхода Параметр сглаживания REML оракула асимптотически суб-оптимально. Однако дисперсия оценки на основе REML оказывается меньше, чем оценка C_p Маллоуза.

тор. Также Рейсс и Огден ([2009 г.](#)) показывают, что при конечной выборке (см., например, Rodríguez-Álvarez et al. [2018](#) для примера в размерах AIC и GCV склонны к недосглаживанию и более вероятно развитие множественных минимумов, чем REML (см. также Дресина [2017 г.](#), Глава 6). Дополнительный аргумент в пользу REML заключается в том, что включение случайных эффектов в модель регрессии со штрафными санкциями проста.

В контексте сглаживания стандартные методы, основанные на REML может применяться, когда используются простые штрафы, т. Е.

на каждый коэффициент регрессии действует один штраф (допускает параметру сглаживания). Однако в некоторых случаях

В некоторых случаях штрафы представляют собой перекрывающуюся структуру, с одинаковыми коэффициентами одновременно штрафуются несколько параметров сглаживания. Сюда входят важные случаи такие как многомерные шлицы со штрафом с анизотропным штрафы или адаптивные штрафные сплайны. Методы оценки которые могут справиться с этой ситуацией, были предложены в литература по сглаживанию (например, Wood [2011](#); Wood et al. [2016 г.](#)), но у них есть недостаток в том, что они очень вычислительны - союзник требователен, особенно когда количество сглаживания параметры большие.

Эта работа решает эту проблему и представляет собой быстрое метод оценки параметров дисперсии / сглаживания параметры в обобщенных линейных смешанных моделях / обобщенные аддитивные модели. Метод может использоваться всякий раз, когда предварительная решающая матрица случайной составляющей (или штрафная матрица модели Р-сплайна) представляет собой линейную комбинацию, определенную над инверсия параметров дисперсии (параметр сглаживания - терс). Получены простые выражения для оценок параметры дисперсии, которые представляют собой отношения между суммой квадратов и величина, связанная с понятием эффективных степеней свобода в контексте сглаживания (Хасты и Тибишрани [1990](#)). Покажем достаточные и необходимые условия того, что гарантировать положительность этих оценок и обсудить несколько. Бывают ситуации, когда эти условия могут быть легко проверены. Были введены частные случаи представленного здесь метода. согласно Родригес-Альваресу и др. ([2015b](#)), которые решили задача в случае анизотропной многомерной гладкой ing, и в работе Rodríguez-Álvarez et al. ([2015a](#)), где результаты для адаптивных Р-шлицев. В последнее время, Дерво и Фазиоло ([2017](#)) расширил вышеупомянутый работает с более общими моделями сплайнов со штрафом. Про-Обсуждаемый здесь posal имеет два основных преимущества с уважение к Вуду и Фазиоло ([2017 г.](#)) подход. Во-первых, оценки параметров сглаживания / дисперсии, описанные в Wood и Фазиоло ([2017](#)) полагаются на псевдообратные формулы Мура – Пенроуза матрицы штрафов, которые, по нашему опыту, могут представлять числовые нестабильности. Во-вторых, наше предложение устанавливает явная связь между оценками компонентов дисперсии и эффективные степени свободы, которых не хватает в Wood и Фазиоло ([2017 г.](#)). Эффективные степени свободы являются ключевыми компоненты в сглаживающих моделях. Они помогают подвести итоги модели, поскольку частичные эффективные степени свободы являются мерой сложность компонентов модели с сильной интуитивной привлекательностью сельскохозяйственное поле).

Остальная часть этого документа организована следующим образом: Разд. [2](#) представляет работу Харвилла ([1977](#)), что составляет фундамент представленной здесь работы. Раздел [3](#) - это Суть статьи: новый метод, получивший название СОП (разделение перекрывающиеся матрицы точности). и кон-связь между СОП и понятием эффективных степеней

свобода обсуждается. Раздел [4](#) описывает несколько Р-шлицев.

модели, к оценке которых можно подойти с помощью СОП. Мы

В этой статье основное внимание уделяется адаптивным Р-сплайнам и Р-сплайнам для

данные иерархической кривой. Иллюстрации с примерами данных представлены

предоставлено в разд. [5](#). Обсуждение закрывает статью. Некоторые технические

Технические подробности добавлены в виде приложений. Оценка

алгоритм подробно описан там.

$$\begin{bmatrix} XR & -1 \\ \underline{ZR} & -1 \end{bmatrix} \begin{bmatrix} Икс \\ XZR \end{bmatrix} = \begin{bmatrix} XR & -1 \\ Z+G & -1 \end{bmatrix} \begin{bmatrix} \beta \\ a \end{bmatrix} \quad \text{знак равно} \quad \begin{bmatrix} XR & -1 \\ ZR & -1 \end{bmatrix} \begin{bmatrix} z \\ z \end{bmatrix}, \quad (2)$$

$$\beta = \begin{pmatrix} XV & -1 \\ XV & -1 \end{pmatrix}^{-1} \begin{pmatrix} Икс \\ XV & -1 \end{pmatrix} z,$$

2 Оценка параметров дисперсии в обобщенные линейные смешанные модели: Harville (1977 г.) и расширения

Этот раздел - наша небольшая дань уважения Харвиллу (1977) статья, что послужило вдохновением для этой работы. Харвилл (1977 г.) В статье рассматриваются подходы ML / REML к параметрам дисперсии. оценки в линейных смешанных моделях (LMM) для гауссовских данные. Тем не менее, оценка GLMM может быть сделана многократное использование методологии LMM на рабочих-зависимых переменная (см., например, Schall 1991; Энгель и Кин 1994 где используются результаты Харвилла (1977 г.). Это подход, которому мы следуем в этой статье.

Пусть $y = (y_1, \dots, y_n)$ вектор из n наблюдений. А GLMM можно записать как

$$g(\mu) = X\beta + Z\alpha, \text{ где } \alpha \sim N(0, G), \quad (1)$$

где $\mu_i = E(y_i | \alpha)$ и $g(\cdot)$ - функция связи. В модель предполагает, что в зависимости от случайных эффектов наблюдения y_i независимо распределены со средним μ_i и дисперсия $\text{Var}(y_i | \alpha) = \phi v(\cdot)$. Здесь $v(\cdot)$ - специфическая заданной дисперсионной функцией, а ϕ - дисперсионный параметр, может быть известным или неизвестным. В модели (1), X и Z представляются разделенные по столбцам матрицы, связанные, соответственно, с фиксированные и случайные эффекты. Мы предполагаем, что X имеет полный ранг, $Z = [Z_1, \dots, Z_c]$ и $\alpha = (\alpha_1, \dots, \alpha_c)$. Каждый Z_k где соответствует матрице плана k -й случайной композиции $\text{rank } \alpha_k$, где α_k - вектор $(q_k \times 1)$ ($k = 1, \dots, c$). Мы далее предположим, что $\alpha_k \sim N(0, G_k)$ и что

$$G = \bigoplus_{k=1}^c G_k = \bigoplus_{k=1}^c \begin{pmatrix} \sigma_k^2 I_{q_k} & 0 \\ 0 & \sigma_k^2 I_{q_c} \end{pmatrix},$$

где I_m - единичная матрица порядка $m \times m$ и \bigoplus обозначает прямая сумма матриц. Обратите внимание, что дисперсия-ковариация матрица G линейна по параметрам дисперсии σ_k^2 .

Как отмечалось ранее, оценка модели (1) можно подойти путем итеративного подбора LMM, включающего рабочую зависимость переменная z и весовая матрица W (обновляются итерация). Конкретный вид z и W приведен в «Приложении.

С». Если ϕ и σ_k^2 ($k = 1, \dots, c$) известны, на каждой итерации обновления для β и α следуют из так называемого метода Хендерсона. уравнения (Хендерсон 1963 г.)

$$A_k = G_k Z_k Z_k^T P z \quad (k = 1, \dots, c), \quad (3)$$

где $P = V^{-1} - V^{-1} I_{kc} X V^{-1} I_{kc} X V^{-1}$ с участием $V = R + ZGZ^T$ и $R = \phi W^{-1}$. Уравнение Хендерсона-малоприспособлен, если параметры дисперсии ϕ и σ_k^2 ($k = 1, \dots, c$) неизвестны. В своей статье 1977 года Харвилл показывает, как оценить их с помощью REML элегантно итеративным Живой алгоритм. Давайте сначала определим

$$T = (I + 3 C Z G)^{-1},$$

где $S = R^{-1} - R^{-1} I_{kc} X R^{-1} I_{kc} X R^{-1}$. Мы заметили что T можно разбить следующим образом

$$T = \begin{bmatrix} T_{11} & T_{12} & \dots & T_{1c} \\ T_{21} & T_{22} & \dots & T_{2c} \\ \dots & \dots & \dots & \dots \end{bmatrix},$$

$$T = T_{c1} T_{c2} \dots T_{cc}$$

где T_{ij} - матрицы порядка $q_i \times q_j$. В Харвилле (1977 г.), обновленная оценка σ_k^2 ($k = 1, \dots, c$) равно

$$A_k = \frac{ED_k^{[m]} A_k^{[m]}}{ED_k^{[m]}}, \quad (4)$$

$$ED_k^{[m]} = q_k - \text{след} T_{kk}^{[m]}, \quad (5)$$

а верхний индекс $[m]$ обозначает величины, оцененные в текущем оценки параметров дисперсии. Из оценок β и α следуют оценку для $z: z = X\beta + Z\alpha$. Остатки являются $z - z$. Харвилл использует

$$\phi = \frac{z^T W (z - z)}{n - \text{rang}(X)}, \quad (6)$$

для оценки параметра дисперсии (не всегда требуется в GLMM). Альтернативное выражение (см., Например, Engel 1990; Родригес-Альварес и др. 2015b)

$$\phi = \frac{z^T W \sum_{k=1}^c z - z}{n - \text{rang}(X) - \sum_{k=1}^c ED_k^{[m]}}, \quad (7)$$

123

Здесь $\text{rang}(X) + \sum_{k=1}^c ED_k^{[m]}$ можно интерпретировать как эффект Размерность модели. При сходимости уравнения (6) и (7) дайте одинаковые числовые значения.

2.1 Эффективные степени свободы в системе Харвилла метод

Как отмечает Харвилл (1977 г.), итерации, полученные из выражения сион (4) имеют интуитивно привлекательную форму. На каждой итерации σ_k^2 оценивается как отношение суммы квадратов оценки для α_k и числа от нуля до q_k . Мы Теперь покажем, что знаменатель в выражении (4) действительно может интерпретироваться как эффективные степени свободы при сглаживании sensu, т. е. как след «шляпной» матрицы (Hastie и Tibshirani 1990).

Сначала обратите внимание, что выражение (3) Показывает, что $Z_k \alpha_k$ $Z_k G_k Z_k^T P z$. Таким образом, матрица «шляпа», соответствующая k -я случайная компонента α_k равна

$$g(\mu) = X\beta + Z\alpha = X\beta + \sum_{k=1}^c Z_k \alpha_k, \quad (10)$$

где $\alpha_k \sim N(0, G_k)$, $\alpha \sim N(0, G)$ и $G = \bigoplus_{k=1}^c G_k$. Основное отличие от разд. 2 это то, что мы не Предположим, что $G_k = d_k^2 I_{q_k}$, но мы рассматриваем матрицы точности

$$G_k = \sum_{l=1}^{\infty} \frac{1}{\lambda_{kl}} \alpha_{kl} \alpha_{kl}^T, \quad (11)$$

$$H_k = Z_k G_k Z_k P,$$

т.е., $H_k = Z_k A_k$. Теперь покажем, что $\text{tr}(H_k) = \text{ED}_k$. Это легко проверить, что

$$T = (I + Z_t S Z G)^{-1} = G^{-1} (I + Z_t S Z)^{-1}, \quad (8)$$

где $(I + Z_t S Z)^{-1}$ это разбиеие, обратное к C в (2), соответствующий случайному вектору a (Hagville 1977 г.; Джонсон и Томпсон 1995). Использование блочной структуры из Z и G , и с использованием результата (8) и (A4) в Джонсоне и Томпсон (1995), мы имеем

$$Z_k P Z_k G_k = I_{q_k} - G_k^{-1} C_{kk}^* = I_{q_k} - T_{kk}, \quad (9)$$

где для облегчения обозначений C_{kk}^* обозначает обратное к C и C_{kk} обозначает это разбиеие C соответствующий k -й случайная составляющая a_k . Таким образом,

$$\begin{aligned} \text{след}(H_k) &= \text{след} \begin{pmatrix} Z_k G_k Z_k P \\ I_{q_k} - T_{kk} \end{pmatrix} = \text{след} \begin{pmatrix} Z_k P Z_k G_k \\ I_{q_k} - T_{kk} \end{pmatrix} \\ &= \text{след} \begin{pmatrix} Z_k G_k Z_k P \\ I_{q_k} - T_{kk} \end{pmatrix} = q_k - \text{след}(T_{kk}) \\ &= \text{ED}_k. \end{aligned}$$

3 Разделение точности перекрытия матрицы: метод СОП

В предыдущем разделе мы обсудили оценку метод для обобщенных линейных смешанных моделей, где дисперсионно-ковариационная матрица случайной составляющей: линейно по параметрам дисперсии. Однако более сложные

где $\sigma^2_{k_l}$ ($l = 1, \dots, p_k$ и $k = 1, \dots, c$) - дисперсия параметры и k_l известны симметричные положительные полу-определенные матрицы размерности $q_k \times q_k$. Обратите внимание, что мы не требуют, чтобы k_l было положительно определенным. Единственное требование мы нужно, чтобы G_k ($k = 1, \dots, c$) положительно определены, поэтому являются обратные, то ковариационная матрица G .

Выражение (11) заслуживает подробного обсуждения. Во-первых, стоит отметить, что мы не работаем с дисперсией - ковариационные матрицы, но с их обратными, точность матрицы. Как уже было сказано, разработки в этой работе имеют свои origin по штрафным сплайн-методам. В разд. 4, необходимость работать с прецизионными матрицами станет ясно, или, в терминология штрафных шлицев, со штрафной матрицей ses. Во-вторых, в чем состоит основной вклад этого В статье предполагается, что каждая случайная компонента a_k ($k = 1, \dots, c$) в модели (10) могут быть "затронуты" (сжаты) из-за несколько параметров дисперсии. Частным случаем будет, когда $p_k = 1 \forall k$, и в этом случае мы находимся в обсуждаемой ситуации в разд. 2.

Для простоты в некоторых случаях перепишем матрица точности G^{-1} следующим образом

$$G^{-1} = \sum_{l=1}^n \sigma_{\lambda}^{-2} \tilde{I}_l, \quad (12)$$

$$\sum_c$$

где $p = \kappa = 1 p_k$. Слегка злоупотребляя обозначениями, пусть l обозначим матрицы, входящие в выражение (11). Матрица \tilde{I}_l является λ продолженной с нулями. Некоторые конкретные примеры будут

быть представлены в разд. 4 ниже. Выражение (12) проясняет что в настоящей работе рассматривается ситуация обобщенного линейные смешанные модели с матрицей точности для случайных составляющая, линейная по параметрам точности σ^{-2}_{λ} .

123

В следующем разделе представлен предлагаемый метод оценки, что мы называем СОП.

3.1 Метод СОП

Независимо от структуры G , оценка β и a , и, при необходимости параметр дисперсии ϕ не задает проблема, и это можно сделать, как описано в Разд. 2 выше (см. также «Приложение С» для подробного описания оценки алгоритм). Напомним, что оценки для a_k получаются as $a_k = G_k Z_k P z$. Матрица шляпы, связанная с k -м случайным Компонента a_k снова равна $H_k = Z_k G_k Z_k P$ и эффективные степени свободы этой компоненты $\text{ED}_k = \text{след}(H_k)$. Параметры дисперсии $\sigma^2_{k_l}$ ($l = 1, \dots, p_k$ и $k = 1, \dots, c$), однако нельзя оценить с помощью Подход Харвилла. Это следствие того, что G не линейно по параметрам дисперсии.

Ключ нашего подхода - работа с G^{-1} вместо с G . Учитывая, что G^{-1} линейна по параметрам точности σ_{λ}^{-2} , частные производные первого порядка от (приближенной) Функция логарифмического правдоподобия REML может быть явно получена как а также основанные на REML оценки параметра дисперсии эфиры. Сформулируем результат в следующей теореме, в которой доказательство приведено в «Приложении А».

Теорема 1 Пусть $G = \sum_{k=1}^c G_k$ - симметричная положительная дефинитная матрица, G_k - симметричный положительный полуопределенный и k_l известный симметричный положительный полуопределенный. Затем оценка дисперсии на основе REML обновляется. параметры $\sigma^2_{k_l}$ ($l = 1, \dots, p_k$ и $k = 1, \dots, c$) даны

Теорема 2 Если $\sigma^2_{k_l[m]} > 0$, то оценка на основе REML обновления параметров дисперсии, указанных в выражении (13) больше или равны нулю со строгим неравенством, если:
(i) $\text{rang}(X, Z_k G_k^{-1}) > \text{rang}(X)$; и (ii) z (рабочий вектор ответа) не находится в пространстве, занимаемом столбцами из X .

Доказательства приведены в «Приложении В». Отметим, что соп-определение (i) необходимо как для числителя, так и для знаменателя выражения (13) быть строго положительным, а (ii) - только необходимо для числителя. С прикладной точки зрения, несомненно, важно иметь возможность проверить, условия выполняются перед подгонкой модели. Это может непростая задача, так как они зависят от G^{-1} и, таким образом, может варьироваться от итерации к итерации. Однако есть общие ситуации, когда условие (i) можно проверить заранее:

- Если k_l имеет полный ранг, то условие (i) упрощается до $\text{rang}(X, Z_k) > \text{rang}(X)$. Отметим, что это условие то же, что обсуждал Харвилл (1977 г.) в лемме как
- Если G_k^{-1} и k_l коммутируют (т.е. $G_k^{-1} k_l = k_l G_k^{-1}$), то условие (i) упрощается до ранжирования $Z_k k_l > \text{rang}(X)$. Примеры, когда G_k^{-1} а также k_l коммутируют, включают, для Например, когда оба диагональны.

Мы обсуждаем эти ситуации более подробно в разд. 4, где некоторые примеры применения метода СОП предварительно отправлено.

от

$$\sigma_{k,l}^2 = \frac{A_{k,l}^{[m]}}{ED_{k,l}^{[m]}} \quad (13)$$

где

$$ED_{k,l}^{[m]} = \text{след} \left(\mathbf{Z}_k \mathbf{P}^{[m]} \mathbf{Z}_k \mathbf{G}_k^{[m]} \sigma_{k,l}^2 \right) \quad (14)$$

с α и $\mathbf{P}_m^{[m]}$ и $\mathbf{G}_k^{[m]}$ оцениваются по текущим оценкам $\Sigma_{k,l}^2$ ($l = 1, \dots, p$ и $k = 1, \dots, c$) и, при необходимости, $\Phi^{[m]}$.

Отметим, что когда $\mathbf{G}_k = \sigma_{k,l}^2 \mathbf{I}_{q_k}$, выражения (13) и (14) сводятся к выражениям Харвилла [выражения (4) и (5), соответственно].

Важное и желаемое свойство данных обновлений в выражении (13) состоит в том, что они всегда неотрицательны, — при том, что предыдущие оценки параметров дисперсии неотрицательны. Кроме того, в достаточно слабых условиях эти обновления строго положительные (хотя возможно получить значения, очень близкие к нулю).

3.2 Эффективные степени свободы в методе СОП

В соответствии с методом Харвилла, обсуждаемым в разд. 2, то знаменатель выражения (13) был обозначен как $ED_{k,l}$, от эффективных степеней свободы. Результат (14) упрощает чтобы показать, что сумма $ED_{k,l}$ по параметру дисперсии p участники \mathbf{G}_k [см. (11)] соответствует ED_k (эффективные степени свободы α_k)

$$\sum_{l=1}^p ED_{k,l} = \text{след} \left(\mathbf{Z}_k \mathbf{P} \mathbf{Z}_k \mathbf{G}_k \right) = \text{след} \left(\mathbf{H}_k \right) = ED_k.$$

Как следствие, при сходимости расчетная эффективная степени свободы, связанные с каждой случайной композицией, в модели (10) получены как побочный продукт СОП метод.

В завершение этой части хотелось бы отметить интересный связь между верхней границей для $ED_{k,l}$ (обозначается $ED_{ub,k,l}$) и условием (i) теоремы 2. Можно показать, что

123

$$ED_{k,l} \leq \text{ранг} \left(\mathbf{X}, \mathbf{Z}_k \mathbf{G}_k \right) - \text{ранг}(\mathbf{X}) = \text{ранг} \left((\mathbf{I}_n - \mathbf{P}_X) \mathbf{Z}_k \mathbf{G}_k \right) = ED_{ub,k,l},$$

где $\mathbf{P}_X = \mathbf{X} \mathbf{X}^T \mathbf{X} \mathbf{X}^T \mathbf{X}$. Таким образом, если условие (i) в огем 2 не проверяется, $ED_{k,l}$ будет в точности равным нулю. Мы опускаем доказательство предыдущего результата. Его можно получить в сим-Таким же образом, как в статье Cui et al. (2010 г.) (см. Интернет Приложение (f) к этому документу), отмечая, что

$$ED_{k,l} = \text{след} \left(\mathbf{Z}_k \mathbf{P} \mathbf{Z}_k \mathbf{G}_k \sigma_{k,l}^2 \right) = \text{след} \left(\mathbf{Z}_k \mathbf{G}_k \sigma_{k,l}^2 \mathbf{G}_k \mathbf{Z}_k^T [(\mathbf{I}_n - \mathbf{P}_X) \mathbf{V} (\mathbf{I}_n - \mathbf{P}_X)] \right) +$$

где $+$ обозначает псевдообратную матрицу Мура – Пенроуза. Эта эквивалентность была доказана в менее общей ситуации: Родригес-Альварес и др. (2018 г.) (см. веб-приложение D в этой статье). Следуя аналогичным рассуждениям, получаем оценка сверху эффективных степеней свободы k -й случайный компонент

$$ED_k \leq \text{ранг}(\mathbf{X}, \mathbf{Z}_k) - \text{ранг}(\mathbf{X}) = \text{ранг}((\mathbf{I}_n - \mathbf{P}_X) \mathbf{Z}_k) = ED_{ub,k}.$$

Используя известный результат, что ранг матричной суммы не может превышать сумму рангов слагаемых матриц, у нас есть этот $ED_{k,l} \leq \sum_{l=1}^p ED_{k,l}$. Однако в целом это является строгим неравенством, так как в большинстве случаев

$$C(\mathbf{Z}_k \mathbf{G}_k) \cap C(\mathbf{Z}_k \mathbf{G}_k) = \{\mathbf{0}\} \quad (u = v),$$

где $C(\mathbf{A})$ обозначает линейное пространство, натянутое на столбцы группы \mathbf{A} (см., например, теорему 18.5.7 в Харвилле 1997 г.). Интуитивно мы можем интерпретировать это как своего рода соревнование между p «Элементами», связанные с k -м случайным компонентом. В $ED_{k,l}$ не может «свободно» меняться от 0 до $ED_{ub,k,l}$, но у них есть для обеспечения того, чтобы их сумма не превышала $ED_{ub,k}$.

3.3 Вычислительные аспекты

(2)] Вычисляется для оценки β и α . Таким образом вычисление трасс, необходимых для реализации алгоритма Ритм сводится к вычислению диагональных элементов из $\mathbf{G}_k - \mathbf{C}_{kk}$. Кроме того, в тех случаях, когда k равно диагонали, только поэлементное произведение диагоналей $\mathbf{G}_k - \mathbf{C}_{kk}$ и нужен k . Это значительно снизит количество требуемых операций и, следовательно, вычисление время.

4 Штрафное сглаживание и метод SOP

В этом разделе обсуждается несколько ситуаций в Р-сплайне. структура, в которой к оценке можно подойти с помощью Метод СОП. Как будет видно, этот метод можно использовать, когда: когда на один и тот же коэффициент действуют несколько штрафов. cients. Анизотропные Р-сплайны тензорного произведения являются примером накладывающиеся штрафы, и это широко обсуждалось в статье Родригеса-Альвареса и др. (2015b). Тем не менее, множественные штрафы возникают в более широком классе ситуаций. Мы опишите здесь два из них: пространственно-адаптивные Р-сплайны и Р-сплайны для данных иерархической кривой.

4.1 Пространственно-адаптивные Р-шлицы

Рассмотрим задачу обобщенной регрессии

$$g(\mu_i) = f(x_i), \quad i = 1, \dots, n, \quad (15)$$

где $\mu_i = E(y_i)$, $g(\cdot)$ - функция связи, $f(\cdot)$ - гладкая и неизвестная функция. Далее мы предполагаем, что $Y(y_i) = \varphi v(\mu_i)$. В каркасе Р-шлицев (Эйлерс и Маркса 1996) неизвестная функция $f(x)$ аппроксимируется линейной комбинацией d В-сплайнов базисных функций, т. е. $f(x) = \sum_{j=1}^d \theta_j B_j(x)$. В матричных обозначениях модель (15) является таким образом выражается как

$$g(\mu) = \mathbf{B}\theta, \quad (16)$$

где $\mu = (\mu_1, \mu_2, \dots, \mu_n)$, $\theta = (\theta_1, \theta_2, \dots, \theta_d)$ и \mathbf{B} представляет собой В-сплайн-матрицу регрессии размерности $n \times d$, т. е. $b_{ij} =$

С вычислительной точки зрения оценка выражение, данное в (14) может быть очень дорогостоящим. Однако это вычисления можно упростить, используя результат, приведенный в (9). Для наших целей легко показать, что

$$\text{след} \begin{pmatrix} \mathbf{Z}^T \mathbf{P} \mathbf{Z} \mathbf{G} \mathbf{G}^T \mathbf{G} \mathbf{G}^T \end{pmatrix} = \text{след} \begin{pmatrix} \mathbf{G}^T \mathbf{Z} \mathbf{P} \mathbf{Z} \mathbf{G} \mathbf{G}^T \end{pmatrix} = \text{след} \begin{pmatrix} \mathbf{G}^T \mathbf{G} - \mathbf{C} \end{pmatrix}.$$

Этот результат используется в описанном алгоритме оценки. в «Приложении С». Отметим, что \mathbf{C}^{-1} [т.е. обратное \mathbf{C} в

$B_j(x_i)$ - j -й В-сплайн, вычисленный в x_i . Гладкость достигается за счет наложения штрафа на коэффициенты регрессии θ в виде

$$\lambda \sum_{k=\delta+1}^d (\theta_k - \theta_{k-1})^2 = \lambda \theta^T \mathbf{D}_q \mathbf{D}_q^T \theta, \quad (17)$$

где λ - параметр сглаживания, а \mathbf{D}_q образует дифференциальный оператор порядка q на соседние коэффициенты, т.е. $\mathbf{D}_q \theta = (\theta_k - \theta_{k-1}, \theta_k - \theta_{k-2}, \dots, \theta_k - \theta_{k-q+1})^T$. Наконец, \mathbf{D}_q есть просто матричное представление q -го разности.

123



Рис. 1 Графическое представление разностей 2-го порядка на соседние коэффициенты базисных функций кубических В-сплайнов. Обратите внимание на местные и заказанные характер этих различий

Как можно увидеть в уравнении (17), то же сглаживание параметр λ применяется ко всем разностям коэффициентов, независимо от TIVE от их местоположения (см. 1). Таким образом, модель предполагает что необходимо одинаковое сглаживание вся область ковариаты. Адаптивные Р-шлицы (см., Например, Кривоногова и соавт. 2008 ; Рупперт и Кэрролл 2000 среди другие) ослабляют это предположение. Идея проста, заменить глобальный параметр сглаживания параметрами сглаживания которые варьируются локально в зависимости от значения ковариаты. Это достигается путем указания другого параметра сглаживания - ξ_u для каждой разности коэффициентов (Рупперт и Кэрролл 2000 г.; Древесина 2011)

$$\sum_{k=\delta+1}^d (\theta_k - \theta_{k-1})^2 = \theta^T \mathbf{D}_q \text{diag}(\xi) \mathbf{D}_q^T \theta, \quad (18)$$

где $\lambda = (\lambda_1, \dots, \lambda_{d-q})$. Обратите внимание, что этот подход подразумевают столько параметров сглаживания, сколько различаются коэффициенты (т.е. $d-q$), что может привести к недостаточному сглаживанию и нестабильные вычисления. Учитывая местный и упорядоченный характер разностей коэффициентов (см. 1), мы можем смоделировать параметры сглаживания λ_k как гладкая функция от k (его положения ции) и используйте для этой цели В-сплайны (здесь нет штрафа. предполагается)

$$\lambda = \xi, \quad (19)$$

где матрица регрессии В-сплайна размерности $(d-q) \times p$ и $\xi = (\xi_1, \dots, \xi_p)$ это новый вектор параметров сглаживания. Выполняя некоторые простых алгебраических операций, можно показать, что адаптивная

$$\theta^T \sum_{l=1}^p \xi_l \mathbf{D}_q \text{diag}(\psi^l) \mathbf{D}_q^T \theta, \quad (20)$$

где ψ^l обозначает столбец l таблицы. Обратите внимание, что под этим адаптивный штраф, все коэффициенты штрафуются множеством параметры сглаживания, т.е. есть накладывающиеся штрафы.

4.1.1 Повторная параметризация смешанной модели

Оценка Р-сплайн-модели (16) при условии адаптации размер штрафа, определенный в (20) может осуществляться на основе связь между Р-шлицами и смешанными моделями (например, Сигге и Дурбан 2002 г.; Жезл 2003). Легко показать, что нуль пространство (т.е. непенализованное функциональное пространство) адаптивного матрица штрафов $\mathbf{P}_{Ad} = \sum_{l=1}^p \xi_l \mathbf{D}_q \text{diag}(\psi^l) \mathbf{D}_q^T$ не зависит от вмятина ξ . Кроме того, заметим, что при $\xi_u = \xi_v = \lambda$ ($\forall u, v$) тогда

$$\sum_{l=1}^p \xi_l \mathbf{D}_q \text{diag}(\psi^l) \mathbf{D}_q^T = \lambda \mathbf{D}_q \mathbf{D}_q^T = \mathbf{P}.$$

Это следствие строк регрессии В-сплайна. матрица с суммой до 1. Таким образом, нулевое пространство \mathbf{P}_{Ad} является же, как и \mathbf{P} . Различные изменения параметров Р-шлица модели предлагались в литературе (см., например, Сигге и Дурбан 2002 ; Эйлерс 1999), все стремятся разложить модель на штрафную и штрафную части. В Следствием этого разложения является то, что штрафная матрица репараметризованной модели Р-сплайна имеет полный ранг, как и матрица точности соответствующей смешанной модели. Для В нашем приложении мы используем предложение, данное в Eilers (1999). Как будет видно, этот подход обеспечивает диагональную точность.

с вычислительной точки зрения. Использование Eilers([1999 г.](#)) трансформация, модель (16) переформулируется как

$$g(\mu) = B\theta = X\beta + Z\alpha,$$

$$\text{где } X = \begin{bmatrix} 1 & | & x & | \dots & | & H K C^{(q-1)} \end{bmatrix} \text{ и } Z = B D_q \quad (D_q D_q)^{-1},$$

$$\mathcal{F}_{\text{рам}}^{-1} = \frac{1}{\varphi} \mathbf{F} \mathbf{P}_{Ad} \mathbf{F} = \sum_{l=1}^n \frac{(\quad)}{\sigma_x^{-2} \text{ диагональ}} \sum_{l=1}^n \text{знак равенства} \sim l, \quad (21)$$

где $F = D_q$, $D_q D_q$, $\sim_l = \text{diag} \quad \psi^l$, а $\sigma_2 = \varphi / \xi_l$. Таким образом, матрица точности линейна по точности параметры σ_2^{-2} , и поэтому можно использовать метод СОП.

Отметим, что модель имеет единственную случайную составляющую ($c = 1$). Повторная параметризация гарантирует, что $\text{rank}(X, Z) = \text{rank}(X) + \text{rank}(Z)$. Таким образом, $\text{rank}(X, Z^{-1}) = \text{rank}(X) + \text{rank}(Z^{-1}) > \text{rank}(X)$. Используя тот факт, что G и \tilde{I} диагональны, а значит, коммутируют, условие (i) теоремы 2 доведен.

4.2 Р-сплайны для данных иерархической кривой

Для простоты предположим, что данные сбалансированной иерархической кривой. $l = 2$

Наши данные состоят на m особей каждый с S - разным те-
измерения в моменты времени $t = (t_1, t_2, \dots, t_s)$. Наш интер-
на

$$x_{p\alpha\beta\gamma\delta}^{(ij)} = f(t_i) + g_j(t_i), 1 \leq i \leq s, 1 \leq j \leq m, \quad (22)$$

где $\mu_{ij} \equiv E \left(\begin{matrix} y_{ij} \\ y_{ij} \end{matrix} \right)$, y_{ij} - переменная ответа на j -й субъект в момент времени t , $f(\cdot)$ - функция, описывающая эффект популяции, $g_j(\cdot)$ - случайные функции, измеряемые отклонение j -го субъекта от популяции (\cdot) эффект. Как и прежде, $\text{Яр } y_{ij} \equiv \varphi v_{ij} \mu_{ij}$. Простая модель будет заключаться в параметрической спецификации для $f(\cdot)$ и $g_j(\cdot)$, например, $f(t) = \beta_0 + \beta_1 t$ и $g_j(t) = \varphi_{0j} + \alpha_{1j} t$, где $\alpha_0 = (\alpha_{01}, \dots, \alpha_{0m}) \sim N(0, \sigma_\theta^2 \mathbf{J}_m)$ и $\alpha_1 = (\alpha_{11}, \dots, \alpha_{1m}) \sim N(0, \sigma_\theta^2 \mathbf{J}_m)$.

Более гибкий подход состоит в предположении, что $f(\cdot)$ и $g_j(\cdot)$ гладкая и неизвестная. Важный вклад в Каркас Р-сплайна можно найти у Durban et al. (2005 г.) и Ruppert et al. (2003 г.). Оба подхода основаны на моделирование $f(\cdot)$ и $g_j(\cdot)$ с использованием базиса усеченных линий, построение основано на штрафных методах и линейной смешанной модели. Совсем недавно Джендже и Карри (2010 г.) расширили эти модели и предложили включение дополнительных штраф за отдельные коэффициенты кривой. Авторы утверждают, что это дополнительное наказание необходимо для решения при оценке эффекта популяции. Под

так называемая модель M0 в Djeundje и Currie([2010 г.](#)) бумага, модель ([22](#)) выражается в матричных обозначениях как

$$\mu_{grain}^{(i)} = B \underbrace{\theta}_{f(t)} + \underbrace{\tilde{B}}_{g_j(t)} \underbrace{\theta_j}_{g_j(t)}$$

где $\mu \cdot j = (\mu^{1j}, \dots, \mu^{sj})$ – это средний вектор отклика для j -го индивидуума, а B^1 и B^2 являются B-сплайновой регрессией матрицы возможно разного размера для соответственного покрывающей уляции и индивидуальное отклонение. Вектор θ равен предполагаемому фиксированному, но с учетом штрафа q -го порядка вида $P \sim \lambda (D_q D_q^{-1}) \theta$ – случайный вектор с распределением $N(0, \varphi^2 P)$ где

$${}^{\sim}P = \lambda_2 {}^{\sim}D_{{}^{\sim}q} {}^{\sim}D_{{}^{\sim}q} + \lambda_3 I_{{}^{\sim}d}. \quad (23)$$

Первый член $\lambda_2 \sim D^{-q}$ отвечает за гладкость кривых индивидов, а $\lambda_3 I^{-d}$ обращается к аспект гибкости (см. Djeundje и Currie 2010 для большего подробности). Обратите внимание, что каждый случайный эффект уменьшается (штрафуется) на оба параметра сглаживания λ_2 и λ_3 , и, следовательно, точность матрица $^{-1} \mathbf{G} = 1 / \varphi \sim \mathbf{P}$ линейно по параметрам точности

$$\tilde{G}^J \stackrel{\Sigma^3}{\text{знак равенства}} \tilde{G}^L, \quad (24)$$

$$\sigma_2 = \varphi / \lambda_2 \text{ и } \sigma_2 = \varphi / \lambda_3 \text{ и } \sigma_2 = \varphi / \lambda_q$$

Более компактно выразим модель для всего
образец как

$$z(\mu) = [1_M \otimes B] \& thetas; + [\mathbf{y}_M \otimes \sim B] \sim \& thetas; , \quad (25)$$

где \otimes обозначает произведение Кронекера, μ — знак равно

$$\mu \cdot 1, \dots, \mu \cdot m, \quad \tilde{\theta} = \tilde{\theta}_1, \dots, \tilde{\theta}_m \quad \text{а также}$$

$$\theta \sim N(\mathbf{0}, \mathbf{J}_M \otimes \mathbf{G})$$

Последний шаг необходим для применения метода СОП. для оценки модели (25): разложение

Эффект популяции в штрафной и штрафной частях.

Мы используем здесь подход, основанный на разложении на собственные значения. положение (EVD) штрафа. Пусть $\mathbf{D}_q \mathbf{D}_q = \mathbf{U} \mathbf{U}^T$ - разложение \mathbf{D}_q . Здесь \mathbf{U} обозначает матрицу собственных векторов \mathbf{D}_q . Также диагональная матрица собственных значений. Обозначим также через $\mathbf{U}_+(\cdot)$ и $\mathbf{U}_0(\cdot)$ подматрицы, соответствующие ненулевое и нулевое собственные значения соответственно. В таком случае, модель (25) переформулируется как

идентифицирующих-

$$\mathbf{g}(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\alpha},$$

где $\beta = U + \theta$, $\alpha = \begin{pmatrix} U \\ 0 \end{pmatrix}$, $\theta = \begin{pmatrix} \theta \\ \theta \end{pmatrix}$, $X = [1_M \otimes BU_0]$

и $Z = [1_M \otimes BU_0 + Y_M \otimes B]$. Наконец, $\alpha \sim N(\theta, G)$,

где

$$G^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & \sigma^2 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & \sigma^2 \end{pmatrix} = \sum_{l=1}^3 \sigma_l^{-2} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

с $\sigma^2 = \lambda_l$ а также

$$\begin{aligned} \tilde{\alpha}_1 &= \begin{pmatrix} 1 & 0 \\ 0 & \sigma^2 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & \sigma^2 \end{pmatrix} \\ \tilde{\alpha}_2 &= \begin{pmatrix} 1 & 0 \\ 0 & \sigma^2 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & \sigma^2 \end{pmatrix} \\ \tilde{\alpha}_3 &= \begin{pmatrix} 1 & 0 \\ 0 & \sigma^2 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & \sigma^2 \end{pmatrix} \end{aligned}$$

Матрица точности линейна по параметрам точности

и поэтому подходит для метода СОП. В этом

случай, две случайные составляющие, моделирующие соответственно

кривая численности и индивидуальные отклонения, с

$$Z_1 = 1_M \otimes B + G \quad \sigma_1^{-2} = \sigma^{-2} \quad \sigma_1^{-2} = \sigma^{-2} + \sigma_1^{-2}$$

$$Z_2 = 1_M \otimes B \text{ и}$$

$$G^{-1} = \sigma^{-2} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \sigma^{-2} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \sigma^{-2} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \sigma^{-2} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Напомним, что $X = 1_M \otimes BU_0$, и заметим, что $\text{rang}(1_M \otimes BU_0) =$

$\text{rang}(BU_0)$. Теперь покажем, что условие (i) теоремы 2

выполняется для всех параметров дисперсии:

σ_1^2 : По построению σ_1^2 положительно определен и имеет полный ранг, и $\text{rang}(X, Z_1) = \text{rang}(X) + \text{rang}(Z_1)$. Отмечая, что $\text{rang}(X, Z_1 G_1) = \text{rang}(X, Z_1) > \text{rang}(X)$, состояние проверено.

σ_2^2 : По, например, следствию 18.2.2 в Харвилле (1997), G_2 и $Y_M \otimes D^{-q}$ коммутируют. Таким образом, пока $m > 1$, легко показать, что $\text{rang}(X, Z_2) = \text{rang}(X) + \text{rang}(Z_2)$. Классический результат: $\text{rang}(1_M \otimes BU_0, 1_M \otimes B + D^{-q}) > \text{rang}(BU_0)$.

σ_3^2 : Обратите внимание, что G_2 и $1_M \otimes B$ коммутируют. Как и раньше, пока $m > 1$ легко показать, что $\text{rang}(X, Z_3) = \text{rang}(X) + \text{rang}(Z_3)$. Классический результат: $\text{rang}(1_M \otimes BU_0, 1_M \otimes B + D^{-q}) > \text{rang}(BU_0)$.

5 примеров

В этом разделе представлены несколько примеров данных, в которых СОП

метод представляет собой мощную альтернативу существующим оценкам

Математические процедуры. Мы обсуждаем три различных анализа:

первые два примера относятся к пространственно адаптируемым Р-

шлицы, но каждый из них имеет дело с разной ситуацией

относительно сложности и цели; последний пример посвящен

иллюстрирующий наш метод анализа иерархической кривой

данные. Все вычисления проводились в (64-битной) R 3.4.4.

(Основная команда 2018) и Intel с тактовой частотой 2,30 ГГц на 5-про-

цессор с 15,6 ГБ ОЗУ и Ubuntu 16.04

Операционная система LTS.

5.1 Доплеровская функция

В нашем первом примере мы рассматриваем функцию Доплера.

Это распространенный пример в литературе по адаптивному сглаживанию.

и обсуждался Рупперт и Кэрролл (2000).

Кривобокова и соавт. (2008 г.) и Тибишани (2014 г.), среди прочих

эры. Данные формируются в соответствии с

$$y_i = \sin(4/x_i) + 1.5 + \varepsilon_i, \quad i = 1, \dots, n,$$

где $x_i \sim U[0, 1]$, $\varepsilon_i \sim N(0, 0.2^2)$ и $n = 1000$. Для подгонки

При обработке данных мы предполагаем, что пространственно-адаптивная модель Р-сплайна

обсуждается в разд. 4.1. Мы сравниваем производительность

Метод СОП с реализованным в R-пакете mgcv,

версия 1.8-23, описанная в Wood (2011). Стоит

заметить, что оба подхода реализуют, по сути, одно и то же

адаптивная Р-сплайн модель; единственная разница - это оценка

процедура (и, возможно, репараметризация). Кроме того,

мы также подбираем модель, не предполагая адаптивного штрафа.

В этом случае метод СОП сводится к подходу Харвилла

(см. раздел 2). Во всех случаях мы используем 200 кубических В-шлицев для

представляют собой гладкую функцию вместе с дифференциалом второго порядка.

особенности. Для адаптивных подходов 15 равноотстоящих

кубические В-сплайны используются для параметров сглаживания [см.

Уравнение (19)]. Эти значения выбраны для обеспечения достаточной гибкости

способность к модели. В этой конфигурации всего

15 параметров дисперсии. Рисунок 2а показывает истинное сим-

Вызванная функция Доплера. Рисунок 2b, с показывает, соответственно,

расчетные кривые на основе метода СОП без и

с адаптивным штрафом. Отображаются результаты с использованием MGCV.

на фиг. 2d. Как и ожидалось, оба адаптивных подхода работают

по аналогии. В указанной конфигурации они могут

захватить 7 циклов функции Доплера. С другой стороны,

неадаптивный подход способен уловить только 4 цикла


и представляет очень непостоянные оценки, особенно справа -

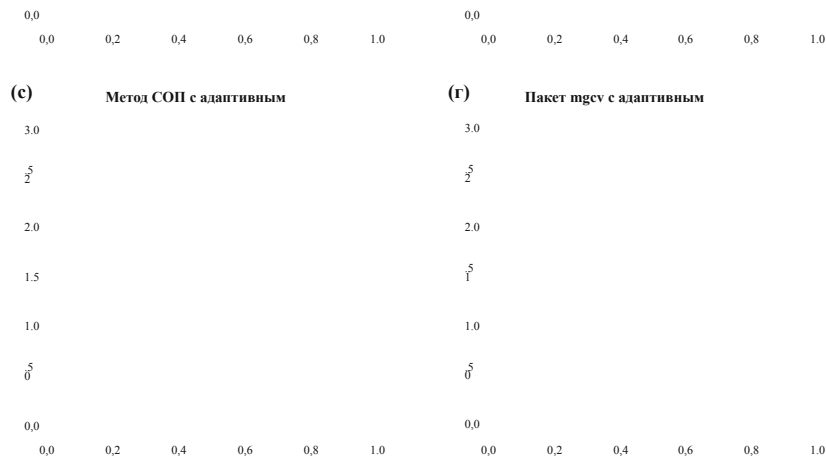
стороны ковариантной области. Что касается ED, то для

Модель СОП без адаптивного штрафа, мы получаем общий ED

95.8 (из 200). Для моделей с адаптивным сглаживанием мы

получили идентичные результаты, т. е. 50.2 (с СОП) и 50.0 (с





Фиг.2. Для функции Дюплера: истинная функция (сплошная линия) и имитировать их обозначенные точки данных (серые точки), **б** оценочная кривая с использованием метода без адаптивного штрафа (сплошная линия) вместе с 95% приблизительным кон- интервалы достоверности (пунктирные линии), **с** оценочная кривая с использованием метода адаптивного штрафа (сплошная линия) вместе с 95% приблизительной конфиденциальностью. **г** оценочная кривая с использованием пакета mgcv с адаптивным штрафом (сплошная линия) вместе с 95% приблизительным доверительным интервалом (пунктирные линии)

MGCV). Стоит помнить, что при использовании метода СОП общий ED получается путем сложения ED, связанных с каждый параметр дисперсии в модели (плюс размер фиксированная часть). Эти ED являются знаменателем оценки обновить выражения параметров дисперсии. Прирост метод СОП становится понятным, если сравнить вычислительные раз: 1 . 0 второй с нашим подходом (0 . 4 , если не считать адаптивный) и 45 секунд с использованием mgcv. Чтобы получить больше информации о выполнении обоих адаптивных подходов за пределами визуальное сходство, показанное на рис. 2 для одного набора данных, мы выполнили небольшое имитационное исследование. Выполняем в общей сложности 100 повторений с той же спецификацией, описанной выше, и производят сравнения относительно среднеквадратичной ошибки (RMSE) и вычислительное время. В терминах RMSE среднее (стандартное отклонение) на 100 повторов равно 0 . +265 (+0 . +0113) для СОП и 0 . 267 (0 . 0121) с использованием mgcv. Что касается времени вычислений, среднее значение (стандартное отклонение) в секундах равно 0 . 84 (0 . 22) и 52 . 79 (30 . 77) для, соответственно, СОП и mgcv.

5.2 Данные дифракции рентгеновских лучей

В этом примере мы используем данные рентгеновской кристаллографии. Физическое радиационное сканирование тонкого слоя оксида индия и олова. Рентгеновский кристаллография позволяет исследовать молекулярные и атомная структура кристаллов. Кристаллографы точно поверните кристалл, указав его желаемую ориентацию, пока он не будет ориентирован пучком рентгеновских лучей. В зависимости от угла количество дифрагированных фотонов меняется, и они обнаруживаются и записываются электронным детектором. Набор данных был проанализирован с помощью пакета diffraction (2008 г., 2013 г.) и его можно найти в R-пакет дифрактометрии как оксид индия. Рисунок 3 показывает такое сканирование дифракции рентгеновских лучей (серые линии). Цель рентгеноструктурный анализ предназначен для определения (а) базы сигнала - линия (и удалите ее); и (б) количество пиков (и выделить их для дальнейшего анализа их положения, высоты, симметрии, и так далее). Этот пример включен исключительно для иллюстрации возможности метода, представленного в этой статье, для анализа

123




Рис. 3 Для примера рентгеновского излучения: оцененное плавное влияние угла дифракции на рентгеновское излучение с использованием метода SOP (сплошное черная линия). Серые линии представляют необработанные данные

анализ очень сложных данных. Для другого подхода к моделированию применительно к этому набору данных, см. Camarda et al. (2016 г.). Учитывая переменная результата представляет данные подсчета, модель Пуассона принят

гарантии могут быть извлечены. FA связана с диффузией воды в мозге, а также с диагностике и прогрессированию рассеянного склероза. Набор данных DTI содержит измерения FA здоровых и больных людей. DTI, зарегистрированные в нескольких местах вдоль тракта мозолистых волокон

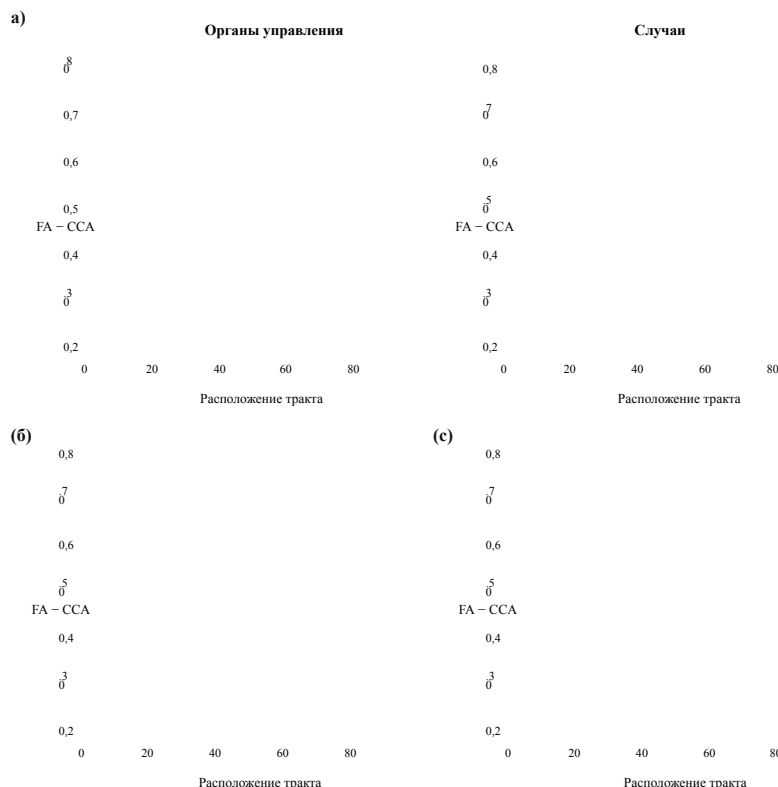
журнал ($E[y_i] = \text{журнал}(\mu_i) = f(x_i)$),

где y_i и x_i ($i = 1, \dots, 2000$) обозначают соответственно количество фотонов и угол дифракции. Чтобы обеспечить достаточно гибкость модели, чтобы она могла улавливать пики (см. 3), мы используем 200 кубических B-сплайнов, а вторые - разницы порядка для функции и 80 кубических B-сплицев для адаптивный штраф. Результаты представлены на рис. 3. Результаты с использованием пакета mgcv почти идентичны нашему гипотезе и не изображены. В этом случае наш метод требует меньше чем 3 с, тогда как MGCV примерно в 750 раз медленнее (33 мин). Что касается ED, всего мы получаем 29.5 и 24.9 с использованием СОП и МКГВ соответственно.

5.3 Данные сканирования визуализации тензора диффузии

Наш последний пример имеет дело с данными иерархической кривой. Мы use набор данных DTI, который можно найти в R-пакете возврат (Goldsmith et al. 2016 г.). Подробное описание исследование и данные можно найти в Goldsmith et al. (2011 г.), Goldsmith et al. (2012 г.) и Гревен и Шейпл (2017 г.). В Короче говоря, исследование было направлено на сравнение участков белого вещества в пациентах, страдающие рассеянным склерозом (РС), и здоровые видео. Рассеянный склероз - заболевание центральной нервной системы, система, которая вызывает поражения в трактах белого вещества, таким образом нарушение прохождения нервных импульсов к головному мозгу и от него и спинной мозг. Визуализация тензора диффузии (DTI) - это магнитное измерение метод визуальной визуализации, позволяющий изучать белое вещество трактуется, отслеживая диффузию воды на мозг. На основе DTI-сканирований измеряется фракционная анизотропия (FA).

(ССА) и правый кортисинальный тракт в головном мозге. Рис. 4а, наблюдаемые измерения FA в разных местах тракта в САА показаны отдельно для случаев и контроля, т. е. лица, пораженные и не пораженные РС. Каждая строка в эти графики представляют человека, и только первое посещение считается. Обратите внимание, что в целом пациенты с РС имеют более низкую Измерения FA, чем у здоровых людей. В целях иллюстрации мы представляем два разных анализа исследования и сравнения. В первую очередь мы сосредотачиваем свой интерес на подгруппа лиц, страдающих рассеянным склерозом. В этой группе всего $m = 99$ особей, каждая с $s = 93$ Измерения FA в разных местах тракта САА. СОП Метод используется для оценки модели, описанной в разд. 4.2 (для гауссовских гомоскедастических ошибок) и представлены в Dje-Ундже и Карри (2010). Для сравнения результатов и вычислений раз код, связанный с работой Джендже и Карри(2010) также тестируется. В этом примере оба реализуют: ментаций используют массивную структуру данные: обобщенные модели линейных массивов (GLAM, Currie et al. 2006) используются для эффективного вычисления внутренних продуктов. для уравнений Хендерсона [Ур. (27)]. Здесь 43 кубических B-сплайновый базис используется для кривой населения, а 23 - для отдельные кривые. Эта конфигурация дает начало модели с 2320 ($= 43 + 23 \times 99$) коэффициентами (оба случайные и исправлено). Методу SOP требуется около 150 секунд, чтобы соответствовать модель, а также Джендже и Карри(2010) код 14 раз медленнее. Отметим, что время вычислений может быть больше и улучшается, если задействована разреженная структура матриц в модели эксплуатируется. Используя матрицу R-пакета, мы можем сократить время вычислений с помощью SOP до 35 секунд. Рисунок 4b показывает предполагаемый эффект популяции



Фиг.4. Для получения данных сканирования диффузии тензорной визуализации: наблюдаемые измерения, основанные на стандартных ошибках полного сэндвича, предложенных Хек-уес вдоль тракта САА. Слева: здоровые элементы управления. Справа: пациенты с рассеянным склерозом. Обратная линия - это наблюдаемое среднее, а пунктирная линия b расчетный профиль FA в популяции (группе) для лиц, затронутых РС. Сплошная красная линия: метод СОП. Пунктирная синяя линия: Djeundje и Currie (2010) код. Пунктирные красные линии обозначают точечную достоверность 95%.

$$\sigma_{k_i}^2 = \text{след} \begin{pmatrix} A_{k_i}^{[m]} & \kappa_i \alpha_{k_i}^{[m]} \\ Z_k n^{[m]} & Z_k G_k^{[m]} \end{pmatrix} C_{k_i}^{-1} \begin{pmatrix} A_{k_i}^{[m]} & \kappa_i \alpha_{k_i}^{[m]} \\ Z_k n^{[m]} & Z_k G_k^{[m]} \end{pmatrix}.$$

знак равно

$$\text{след} \begin{pmatrix} A_{k_i}^{[m]} & \kappa_i \alpha_{k_i}^{[m]} \\ Z_k n^{[m]} & Z_k G_k^{[m]} \end{pmatrix} \Sigma_{k_i}^{-1} \begin{pmatrix} A_{k_i}^{[m]} & \kappa_i \alpha_{k_i}^{[m]} \\ Z_k n^{[m]} & Z_k G_k^{[m]} \end{pmatrix}.$$

В Доказательство теоремы 2

Доказательство Прежде всего напомним некоторые обозначения и введем некоторые нужные результаты. Обозначим как $P = V^{-1} - V^{-1} I_{n-k} X V^{-1} I_{n-k}$, где $V = R + ZGZ$, $R = \varphi W$ с бытии диагональная матрица весов, участвующая в подсчете очков Фишера алгоритм.

Обозначим через $C(A)$ линейное пространство, натянутое на столбцы множества A , и пусть $P X V^{-1} = X V^{-1} I_{n-k} X V^{-1} I_{n-k}$ быть ортогональная проекционная матрица для $C(X)$ относительно V^{-1} . Легко показать, что

$$P = V^{-1} \begin{pmatrix} I_n - P X V^{-1} \\ V^{-1} \begin{pmatrix} I_n - P X V^{-1} \\ V^{-1} \begin{pmatrix} I_n - P X V^{-1} \\ V^{-1} \begin{pmatrix} I_n - P X V^{-1} \end{pmatrix} \end{pmatrix} \end{pmatrix}.$$

знак равно

По теореме 14.2.9 Харвилля ([1997]), P является (симметричным) положительная полуопределенная матрица. Кроме того,

$$P X = 0,$$

а также

$$\begin{aligned} \text{ранг}(P) &= \text{ранг} \begin{pmatrix} V^{-1} \begin{pmatrix} I_n - P X V^{-1} \\ V^{-1} \begin{pmatrix} I_n - P X V^{-1} \\ V^{-1} \begin{pmatrix} I_n - P X V^{-1} \end{pmatrix} \end{pmatrix} \end{pmatrix} \\ &= \text{ранг} \begin{pmatrix} I_n - P X V^{-1} \\ P X V^{-1} \end{pmatrix} \\ &= n - \text{ранг} P X V^{-1} \\ &= n - \text{ранг}(X). \end{aligned}$$

Таким образом,

$$\ker(P) = C(X), \quad (26)$$

т.е. $Px = 0$ тогда и только тогда, когда x находится в $C(X)$.

Пусть $k_i = U U^T$ - разложение на собственные значения κ_i . Отметим, что $k_i = U^+ + U^+$, где $U^+ = U U^T$ - подматрица, соответствующие ненулевым собственным значениям. потом

$$\alpha_{k_i} = \kappa_i \alpha_{k_i} \text{ и } \alpha_{k_i} = \alpha_{k_i} U^+ + \alpha_{k_i} U^+ = Z P Z_k G_k U^+ + U^+ G_k Z_k P z \geq 0,$$

с равенством тогда и только тогда, когда $U^+ G_k Z_k P z = 0$ (поскольку $+$ положительно определен). Таким образом, используя результат (26) равенство

выполняется, если z принадлежит $C(X)$ или $C(Z_k G_k U^+) \subset C(X)$. По лемме 4.2.2 и следствие 4.5.2 в Харвилле ([1997]), у нас есть

$$C(Z_k G_k U^+) = C \begin{pmatrix} Z_k G_k k_i \\ Z_k G_k k_i, X \end{pmatrix} \subset C(X) \iff \text{ранг} \begin{pmatrix} Z_k G_k k_i \\ Z_k G_k k_i, X \end{pmatrix} = \text{ранг}(X).$$

П.О. Относительно знаменателя оценок на основе REML обновления, мы следуем аналогичным рассуждениям. Использование следствия 14.7.5 (и теорема 14.2.9) в Харвилле ([1997]), имеем

$$\text{след} \begin{pmatrix} Z_k P Z_k G_k k_i G_k \\ U^+ G_k Z_k P Z_k G_k U^+ \end{pmatrix} \geq 0,$$

с равенством тогда и только тогда, когда $U^+ G_k Z_k P Z_k G_k U^+ = 0$. Опять же, это равенство выполняется тогда и только тогда, когда $C(Z_k G_k U^+) \subset C(X)$ (т.е. $\iff \text{ранг} \begin{pmatrix} Z_k G_k k_i \\ Z_k G_k k_i, X \end{pmatrix} = \text{ранг}(X)$). П.О.

С Алгоритм оценки

В этом приложении кратко описаны этапы алгоритма оценки. рифм для модели (10) на основе метода СОП. Напомним, что интерес заключается в оценочной модели

$$g(\mu) = X\beta + Z\alpha = X\beta + \sum_{k=1}^c Z_k \alpha_k,$$

где $Z = [Z_1, \dots, Z_c]$, $\alpha = (\alpha_1, \dots, \alpha_c)$, $\alpha_k \sim N(0, G_k)$ с $G_k = \sum_{l=1}^p \sigma_{k,l}^2 I_{k,l}$ и $\alpha \sim N(0, G)$ с $G = \sum_{k=1}^c G_k$.

Инициализация Установить начальные значения параметров дисперсии $\sigma_{k,l}^2$ ($l = 1, \dots, p$ и $k = 1, \dots, c$). В ситуации, когда ϕ неизвестен, устанавливаются Начальное значение для этого параметра, ϕ и $t = 0$. Шаг 1 Постройте рабочий вектор отклика z и матрица весов W в следующем виде

$$z_j = z(\mu_j) + \epsilon_j, \quad \epsilon_j \sim N(0, \sigma^2), \quad w_{ii} = z(\mu_j)^2 v(\mu_j).$$

Шаг 1.1. Учитывая начальные оценки параметров дисперсии, оценить α и β , решив

$$\begin{bmatrix} X R^{[m]-1} I_{k_c} X R^{[m]-1} Z \\ Z R^{[m]-1} X Z R^{[m]-1} Z + G^{[m]-1} \end{bmatrix} \begin{bmatrix} \beta \\ \alpha \end{bmatrix} = \begin{bmatrix} X R^{[m]-1} z \\ Z R^{[m]-1} z \end{bmatrix}, \quad (27)$$

где $R^{[T]} = \varphi^{[m]} W^{-1}$. Пусть $\alpha^{[m]}\beta^{[m]}$ быть этим оценки.

Шаг 1.2 Обновите параметры дисперсии следующим образом

где $z_j = 1$, если j -й человек подвержен MS (случай) и $z_j = 0$ в противном случае (контроль). Упорядочим данные с сначала наблюдения за элементами управления, а затем наблюдения за

Пациенты с рассеянным склерозом. В матричных обозначениях модель может быть выражена в виде

$$y = [Q \otimes B] \theta + [I_m \otimes \tilde{B}] \tilde{\theta} + \varepsilon, \quad (28)$$

с $B, \tilde{B}, \tilde{\theta}$, как определено в разд. 4.2, и $\varepsilon = (\varepsilon_{11}, \dots, \varepsilon_{1m}, \dots, \varepsilon_{m1}, \dots, \varepsilon_{mm})$, с $\varepsilon_{ij} = \varepsilon_{1j}, \dots, \varepsilon_{mj}$. Матрица Q представляет собой любую подходящую матрицу, траст-матрица размерности $m \times 2$, где $m = m_0 + m_1$, с m_0 - количество элементов управления, а m_1 - количество MS. пациенты. Для нашего приложения мы рассматриваем

$$Q = \begin{pmatrix} 1_{m_0} & 0_{m_0} \\ 0_{m_1} & 1_{m_1} \end{pmatrix},$$

и для f_0 и f_1 предполагается разная степень сглаживания, т.е. матрица штрафа, действующая над вектором коэффициентов θ имеет вид

$$P = \begin{pmatrix} \lambda_1 D_q D_q & 0_{c \times c} \\ 0_{c \times c} & \lambda_2 D_q D_q \end{pmatrix}.$$

Переформулировка смешанной модели может быть выполнена аналогичным образом. мода на описанную в разд. 4.2, в этом случае

$$X = [Q \otimes BU_0],$$

$$\tilde{X} = [Q \otimes BU_+ : I_m \otimes \tilde{B}],$$

а также

$$G^{-1} = \begin{pmatrix} \sigma_1^{-2} + 0_{\partial \times \partial} & 0_{d \times m \times \partial} \\ 0_{\partial \times \partial} & \sigma_2^{-2} + 0_{d \times m \times \partial} \\ 0_{m \times \partial \times d} & 0_{m \times \partial \times c} & Y_m \otimes \tilde{G}^{-1} \end{pmatrix},$$

где

$$\tilde{G}^{-1} = \sigma_2^{-2} \tilde{D} \tilde{q} D^{-1} q + \sigma_4^{-2} Y \tilde{\partial}.$$

Рекомендации

- Бреслоу, Н. Э., Клейтон, Д. Г.: Приближенный вывод в обобщенном линейные смешанные модели. Варенье. Стат. Доц. **88** (421), 9–25 (1993).
- Camarda, CG, Eilers, PH, Gampe, J.: Суммы гладких экспонент к разложить сложные серии отсчетов. Стат. Модель. **16** (4), 279–296 (2016)
- Крайничану, К.М., Рупперт, Д., Кэрролл, Р.Дж., Джоши, А., Гуднер, Б.: Пространственно адаптивные байесовские штрафные сплайны с гетероскедастикой ошибки. J. Comput. График. Стат. **16** (2), 265–288 (2007).
- Крамп, С.Л.: Текущее состояние анализа компонент дисперсии. Биометрики **7** (1), 1–16 (1951)

$\sigma_{k_l}^2 = \frac{A_k^{[m]} \kappa_k \alpha_k^{[m]}}{ED_{k_l}^{[m]}}$

и, при необходимости,

$$\varphi = \frac{\begin{pmatrix} z - X\beta^{[m]} - Z\alpha^{[m]} \end{pmatrix} W \begin{pmatrix} z - X\beta^{[m]} - Z\alpha^{[m]} \end{pmatrix}}{n - \text{ранг}(X) - \sum_{k=1}^c \sum_{l=1}^{p_k} ED_{k_l}^{[m]}},$$

с участием

$$ED_{k_l}^{[m]} = \text{след} \left(\begin{pmatrix} \begin{pmatrix} [t]^* \\ [t]^* \end{pmatrix} \begin{pmatrix} [t]^* \\ [t]^* \end{pmatrix} \end{pmatrix} \begin{pmatrix} [t]^* \\ [t]^* \end{pmatrix} \begin{pmatrix} [t]^* \\ [t]^* \end{pmatrix} \right).$$

Напомним, что $\begin{pmatrix} [t]^* \\ [t]^* \end{pmatrix}$ обозначает обратное к $C^{[m]}$ в (27), и C^{kk} - это разбиение C соответствующий k -й случайной составляющей α_k .

Шаг 1.3 Повторите шаги 1.1 и 1.2, заменив $\hat{\sigma}_{k_l}^2$ $\sigma_{k_l}^2$, а также, если они будут обобщенными до сходимости. Для примеров, представленных в разд. 5, мы используем Отклонение REML как критерий сходимости.

Шаг 2 Повторите шаг 1, заменив параметры дисперсии и фиксированные и случайные эффекты модели (и, следовательно, $M(m)$ на полученные на последней итерации шагов 1.1 – Шаг 1.3, до сходимости.

Стоит отметить, что для удобства записи в примеры, описанные в разд. 4, матрица точности была переписан как $G^{-1} = \sum_{l=1}^c \sigma_{k_l}^{-2} \tilde{L}$, где $p = \sum_{k=1}^c p_k$ - количество параметров дисперсии, \tilde{L} - матрица ses_{k_l} дополнены нулями. Здесь \tilde{L} матрицы размерности $q \times q$, где $q = \sum_{k=1}^c q_k$ - количество ран-коэффициентов эффектов dom. Для этой спецификации оценка Алгоритм, рассмотренный выше, остается по существу тем же самым, но на шаге 1.2 $\alpha^{[t]}$, $G^{[m]}$, $G^{k,k}$ заменяются на соответственно $\alpha^{[t]}$, $G^{[m]}$ и \tilde{L} , и C^{kk} будет тем разбиением C соответствующему случайному вектору α (и, следовательно, то же самое для все параметры дисперсии).

D Посторонняя модель иерархической кривой

В этом приложении подробно описывается фактор за кривой зависимости модель действия, обсуждаемая в разд. 5.3, т.е.

$$y_{ij} = f_{z_i}(t_i) + g_j(t_i) + \varepsilon_{ij} \quad 1 \leq i \leq s, \quad 1 \leq j \leq m,$$

123

Цуй, Й., Ходжес, Дж. С., Конг, Х., Карлин, Б. П.: Степени разделения свобода в иерархических и других моделях с богатыми параметрами. Технометрика **52**, 124–136 (2010)

Карри, И. Д., Дурбан, М.: Гибкое сглаживание с помощью Р-шлицев: унифицированное подход. Стат. Модель. **2** (4), 333–349 (2002).

Карри, И. Д., Дурбан, М., Эйлерс, РНС: Обобщенные модели линейных массивов с приложениями к многомерному сглаживанию. JR Stat. Soc. Сер. В (Стат. Метод.) **68** (2), 259–280 (2006)

Дэвис, П.Л., Гатер, У., Мейз, М., Мергель, Д., Милденбергер, Т.: Остаточная локализация и количественная оценка пиков в рентгеновских лучах дифрактограммы. Аня. Прил. Стат. **2** (3), 861–886 (2008).

Дэвис, П.Л., Гатер, У., Мейз, М., Мергель, Д., Милденбергер, Т., Берн-Холт Т., Хофмайстер Т.: дифрактометрия: идентификация базовой линии и разложение пиков для рентгеновских дифрактограмм. Версия пакета R 0.1-10 (2018)

Djeundje, VA, Cuttice, ID: Соответствующая ковариационная спецификация через штрафы за штрафные шлицы в смешанных моделях для продольных

Хасты, Т.Дж., Тибишери, Р.Дж.: Обобщенные аддитивные модели. Чепмен & Холл, Лондон (1990)

Хекман, Н., Локхарт, Р., Нильсен, Дж. Д.: Штрафная регрессия, смешанная модели эффектов и соответствующее моделирование. Электрон. J. Stat. **7**, 1517–1552 (2013)

Хендерсон, К.Р.: Селекционный индекс и ожидаемый генетический прогресс. Стат. Genet. Порода растений. **982**, 141–163 (1963)

Хантер, Д.Р., Ли, Р.: Выбор переменных с использованием алгоритмов MM. Аня. Стат. **33** (4), 1617–1642 (2005).

Джонсон, Д.Л., Томпсон, Р.: Ограниченная оценка максимального правдоподобия. определение компонентов дисперсии для одномерных моделей животных с использованием методы разреженных матриц и усредненная информация. J. Dairy Sci. **78**, 449–456 (1995).

Карас, М., Бжиски, Д., Джемишч, М., Гони, Дж., Карекен, Д.А., Randolph, TW, Harezlak, J.: Информация о подключении мозга методы регуляризации регрессии. Стат. Biosci. (2017). <https://doi.org/10.1007/s12561-017-9208-x>

- данные. Электрон. J. Stat. **4**, 1202–1224 (2010).
- Дурбан, М., Агилера-Морилю, М.К.: Об оценке функциональных случайные эффекты. Стат. Модель. **17** (1–2), 50–58 (2017)
- Дурбан, М., Харезлак, Дж., Ванд, депутат, Кэрролл, Р.Дж.: Простая установка тематические кривые для продольных данных. Стат. Med. **24** (8), 1153–1167 (2005)
- Eilers, PHC: обсуждение Verbyla et al. JR Stat. Soc. Сер. С (Прил. Стат.) **48**, 300–311 (1999).
- Eilers, PHC, Marx, BD: гибкое сглаживание с помощью B-сплицев и штрафы. Стат. Sci. **11** (2), 89–121 (1996)
- Энгель Б.: Анализ несбалансированных линейных моделей с дисперсионным соединением. Стат. Neerf. **44**, 195–219 (1990).
- Энгель, Б., Буист, В.: Анализ обобщенной линейной смешанной модели: тематическое исследование и результаты моделирования. Биом. J. **38** (1), 61–80 (1996).
- Энгель Б., Кин А. Простой подход к анализу обобщения. линейные смешанные модели. Стат. Neerf. **48** (1), 1–22 (1994)
- Фан, Дж., Ли, Р.: Выбор переменной с помощью невогнутой штрафной вероятности и его оракульные свойства. Варенье. Стат. Доц. **96** (456), 1348–1360 (2001)
- Гилмор, АР, Томпсон, Р., Каллис, Б.Р.: Средняя информация REML: эффективный алгоритм оценки параметров дисперсии в линейных смешанных моделях. Биометрия **51** (4), 1440–1450 (1995)
- Голдсмит, Дж., Бобб, Дж., Крайничану, С.М., Каффо, Б., Райх, Д.: Пенитенциарные меры. рекомендованная функциональная регрессия. J. Comput. График. Стат. **20** (4), 830–851 (2011)
- Голдсмит, Дж., Крайничану, К.М., Каффо, Б., Райх, Д.: продольный штрафной функциональной регрессии для когнитивных результатов на ней-измерения ронального тракта. JR Stat. Soc. Сер. С (Прил. Стат.) **61** (3), 453–469 (2012)
- Голдсмит, Дж., Шайпл, Ф., Хуанг, Л., Вробель, Дж., Геллар, Дж., Харезлак, Дж., Маклин, М. В., Свихарт, Б., Сяо, Л., Крейничану, К., Рейсс, РТ: возврат: регрессия с функциональными данными. Версия пакета R 0,1-16 (2016)
- Грейзер, Х.-У., Смит, С.П., Таер, Б.: Подход без производных для оценка компонентов дисперсии в моделях на животных ограниченным максимальной вероятностью. J. Anim. Sci. **2** (64), 1362–1373 (1987).
- Грин, П.Дж.: вероятность общей полупараметрической регрессии с учетом штрафных санкций с р-образными шлицами. Плевать. Стат. **23**, 52–71 (2018)
- Гревен, С., Шайпл, Ф.: Общая основа функциональной регрессии. моделирование. Стат. Модель. **17** (1–2), 1–35 (2017)
- Groll, A., Tutz, G.: Выбор переменных для обобщенного линейного смешанного модели по L1-штрафной оценке. Стат. Comput. **24** (2), 137–154 (2014)
- Харвилл, Д.А.: Подходы максимального правдоподобия к компоненту дисперсии оценка и связанные с ней проблемы. Варенье. Стат. Доц. **72** (358), 320–338 (1977)
- Харвилл, Д.А.: Матричная алгебра с точки зрения статистики. Спрингер, Берлин (1997)
- Кривобокова, Т.: Выбор параметра сглаживания в двух кадрах. работает для штрафных шлицев. JR Stat. Soc. Сер. В (Стат. Methodol.) **75** (4), 725–741. <https://rss.onlinelibrary.wiley.com/doi/pdf/10.1111/rssb.12010> (2009 г.)
- Кривобокова Т., Крайничану С.М., Кауэрманн Г.: Быстрая адаптивная штрафные шлицы. J. Comput. График. Стат. **17** (1), 1–20 (2008)
- Ли, Д.-Дж.: Смешанная модель сглаживания для пространственных и пространственно-временных данные. Кандидатская диссертация. Департамент статистики Университета Карлоса III де Мадрид, Испания (2010)
- Маккалах, П., Нелдер, Дж.: Обобщенные линейные модели. Чепмен и Монографии Холла / CRC по статистике и прикладной теории вероятностей Серия, 2-е изд. Чепмен и Холл, Лондон (1989)
- Паттерсон, HD, Томпсон, Р.: Восстановление межблочной информации когда размеры блоков не равны. Биометрика, **58** (3), 545–554 (1971)
- Основная группа R: R: Язык и среда для статистической коммуникации положить. Фонд R для статистических вычислений, Вена, Австрия (2018)
- Рейсс П.Т., Огден Р.Т.: Выбор параметра сглаживания для класса полупараметрических линейных моделей. JR Stat. Soc. Сер. В Стат. Методол. **71** (2), 505–523 (2009).
- Родригес-Альварес, М.Х., Дурбан, М., Ли, Д.-Дж., Эйлерс, ПМСЦИ: Быстрое оценивание многомерных адаптивных р-сплайн-моделей. В: Friedl, H., Wagner, H. (eds.) Proceedings of 30th International seminar по статистическому моделированию, стр. 330 - 335. [arXiv: 1610.06861](https://arxiv.org/abs/1610.06861) (2015a)
- Родригес-Альварес, М.Х., Ли, Д.-Дж., Кнейб, Т., Дурбан, М., Эйлерс, РНС: быстрое разделение параметров сглаживания в многомерных обобщенные Р-сплайны: алгоритм SAP. Стат. Comput. **25**, 941–957 (2015b)
- Родригес-Альварес, М.Х., Дурбан, М., Ли, Д.-Дж., Эйлерс, РНС, Гонсалес, Ф.: Пространственно-временные адаптивные штрафные сплайны с приложение к нейробиологии. В: Dupuy, J.-F., Josse, J. (eds.) Материалы 31-го Международного семинара по статистике Моделирование, стр. 267–272. [arXiv: 1610.06860](https://arxiv.org/abs/1610.06860) (2016)
- Родригес-Альварес, МХ, Бур, член парламента, ван Иувийк, Ф.А., Эйлерс, РН: Исправление пространственной неоднородности в экспериментах по селекции растений
- Рупперт Д., Кэрролл Р.Дж.: Пространственно-адаптивные штрафы за подгонку шлицевого соединения. Aust. NZJ Stat. **42** (2), 205–223 (2000)
- Рупперт, Д., Ванд, М. П., Кэрролл, Р.: Полупараметрическая регрессия. Сам-Бридж Университи Пресс, Кембридж (2003)
- Шалл, Р.: Оценка в обобщенных линейных моделях со случайными эффектами. Биометрика **78** (4), 719–727 (1991).
- Симпкин, А., Ньюэлл, Дж.: Подход с аддитивным штрафом р-сплайнов к производной тивная оценка. Comput. Stat. Data Anal. **68**, 30–43 (2013)
- Смит С.П.: Оценка генетических параметров в нелинейных моделях. В: Джанола Д., Хаммонд К. (ред.) Достижения в статистических методах для генетического улучшения животноводства. Продвинутая серия в сельском хозяйстве культурологии, т. 18. Springer, Берлин, Гейдельберг (1990)

- Тейлор, Дж. Д., Вербила, А. П., Кэвзна, К., Ньюберри, М.: Переменная селек- в линейных смешанных моделях с использованием расширенного класса штрафов. Aust. NZJ Stat. **54** (4), 427–449 (2012).
- Тибишрани, Р.Дж.: Адаптивная кусочно-полиномиальная оценка через тренд фильтрация. Аня. Стат. **42**, № 1, 285–323 (2014).
- Wand, MP: Сглаживающие и смешанные модели. Comput. Стат. **18** (2), 223–249 (2003)
- Дерево, SN: быстрая стабильная прямая подгонка и выбор гладкости для генераторов. обобщенные аддитивные модели. JR Stat. Soc. Сер. В (Стат. Метод.) **70** (3), 495–518 (2008).
- Вуд, С.Н.: Быстрая стабильная ограниченная максимальная вероятность и предельная оценка правдоподобия полупараметрических обобщенных линейных моделей. JR Stat. Soc. Сер. В (Стат. Метод.) **73** (1), 2–36 (2011)
- Вуд, С. Н.: Обобщенные аддитивные модели: введение в R, 2-е место. edn. Chapman & Hall CRC, Лондон (2017)
- Вуд, С. Н., Фазиоло, М.: Обобщенный метод Фелльнера-Шалла для оптимизация параметров сглаживания с приложением к Tweedie расположение, масштаб и форма моделей. Биометрия **73**, 1071–1081 (2017)
- Вуд, С. Н., Пья, Н., Сефкен, Б.: Параметр сглаживания и выбор модели. для общих гладких моделей. Варенье. Стат. Доц. **111** (516), 1548–1563 (2016)
- Цзоу, Х., Ли, Р.: Одноступенчатые разреженные оценки в невогнутой форме со штрафом модели правдоподобия. Аня. Стат. **36** (4), 1509–1533 (2008).

